

ARIMA MODELS

1. Modelos autoregresivos (AR)

se basan en la idea de que valores presentes o actuales de la serie pueden ser explicados por valores pasados, es decir; que x_t puede ser explicado por $x_{t-1}, x_{t-2}, \dots, x_{t-p}$; donde p determina el n° de pasos que tienen de ir hacia atrás para averiguar el valor actual.

Ejemplo:

$$x_t = x_{t-1} - 0'90 \cdot x_{t-2} + (w_t)$$

↳ Ruido blanco.

→ La herramienta de ACF es un elemento clave para poder analizar la relación entre valores pasados y actuales de una serie temporal.

→ El uso práctico que tiene el ACF es el de identificar qué lags deben de incluirse en el modelo autoregresivo (determinando p).

DEF

Un modelo autoregresivo de orden p, AR(p) es de la forma:

$$x_t = \phi_1 \cdot x_{t-1} + \phi_2 x_{t-2} + \dots + \phi_p x_{t-p} + w_t,$$

donde x_t es estacionario, $\mu(x_t) = 0$, σ^2 const.

DEF

El operador autoregresivo $\phi(B)$, se define:

$$\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p$$

donde B es el operador de retraso que actúa sobre una serie temporal desplazando sus valores hacia el pasado:

$$\begin{aligned} \cdot Bx_t &= x_{t-1} \\ \cdot B^2x_t &= x_{t-2} \end{aligned}$$

Para AR(1), el $\phi(B)$ es:

$$\phi(B) = 1 - \phi B$$

y entonces

$$x_t = \phi x_{t-1} + w_t$$

Comportamiento de ACF y PACF para AR(1)

- da ACF mide la correlación entre x_t y x_{t-h}

- Para AR(1), la ACF decrece gradualmente de forma exponencial con el lag h . Esto refleja que los valores actuales tienen una dependencia decreciente con valores pasados.

P. ejemplo:

- $|\phi| = 0'7 \Rightarrow$ ACF en el lag 1 será $\rho(1) \approx 0'7$
- $\rho(2) \approx 0'64$, porque $\rho(2) = \phi^2$
- $\rho(3) \approx 0'512$
- ...

- La PACF mide la correlación entre x_t y x_{t-h} eliminando el efecto de los lags intermedios.

- para AR(1) tiene un pico significativo en el lag 1 y luego cae a 0.

- El orden de p en un modelo AR se identifica directamente con el último lag significativo de PACF.

Moving Average Model

DIF El moving average model de orden q, MA(q) es:

$$X_t = w_t + \theta_1 w_{t-1} + \theta_2 w_{t-2} + \dots + \theta_q w_{t-q},$$

dónde q son los lags del m.a y $\theta_1, \dots, \theta_q$ son los parámetros.

(IMP)

En el AR (Auto Regressive) valores pasados explicaban valores actuales. Bien, pues en el MA (Moving Average), el modelo describe como valores actuales de la serie, dependen de los errores (o término de ruido) ocurridos en el pasado.

DIF El moving average operator O(B) es,

$$O(B) = 1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q$$

ejemplo MA(1)

$$X_t = w_t + \theta w_{t-1}$$

X_t = Valor serie temporal tiempo t

w_t = término de ruido blanco con $E(w_t) = 0$ y $\sigma_w^2 = 0$

θ = parámetro del modelo que mide la influencia del ruido en el tiempo $t-1$

• Propiedades esperadas del modelo

• Sabemos que $E(w_t) = 0 \Rightarrow E(X_t) = 0$

• La varianza y covarianza dependen de las propiedades del ruido w_t . Para $h=0, 1, > 1$:

$$\delta(h) = \begin{cases} \cdot (1+\theta^2)\sigma_w^2 & , h=0 \\ \cdot \theta \cdot \sigma_w^2 & , h=1 \\ \cdot 0 & , h>1 \end{cases}$$

Covarianza

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

↑

Autoregressive Moving Average Model (ARMA)

DEF

Una serie temporal $\{x_t, t=0, \pm 1, \pm 2, \dots\}$ es

ARMA(p, q) si es estacionaria y :

$$(1) x_t = \underbrace{\phi_1 x_{t-1} + \dots + \phi_p x_{t-p}}_{\text{AR}} + \underbrace{w_t + \theta_1 w_{t-1} + \dots + \theta_q w_{t-q}}_{\text{NA}}$$

↑
Ruido blanco

Con $\phi_p \neq 0$, $\theta_q \neq 0$ y $\sigma_w^2 > 0$

Se puede escribir también de forma condensada como:

$$(2) \phi(B) \cdot x_t = \theta(B) w_t$$

→ Possible problemas con modelos ARMA

1. Redundancia de parámetros.

Cuando un modelo tiene más parámetros de los necesarios para describir la dinámica de la serie se dice que hay redundancia de parámetros. Esto puede hacer que el modelo parezca más complejo de lo que realmente es, ocultando la verdadera naturaleza de los datos.

Un ejemplo de esto podría ser cuando x_t es todo ruido blanco, o decir, $x_t = w_t$.

Si lo reescribimos de forma manipulada:

$$x_t = 0.5 \cdot x_{t-1} - 0.5 w_{t-1} + w_t$$

Esto parecería apuntar a un ARMA(1,1), pero esto no es correcto porque hay redundancia.

¿Cómo la detectamos? Con los polinomios anulantes:

(*)

Volver a (2) y :

$$\left. \begin{aligned} \phi(B) \cdot x_t &= \theta(B) \cdot w_t \\ (\#) \quad \begin{cases} \phi(B) = 1 - 0.5B \\ \theta(B) = 1 - 0.5B \end{cases} \end{aligned} \right\} \Rightarrow \boxed{x_t = w_t}$$

Ruido blanco /

2. Modelos AR no causales. Dependen de valores futuros.

3. Modelos MA no invertibles.

→ Para evitar estos 3 problemas será necesario imponer restrictiones adicionales:

1) Estacionariedad

2) Causalidad.

Restricciones aplicadas a estos tres problemas

1. Redundancia de parámetros

→ se redifine el ARMA para que esté en la forma más simple:

- $\phi(z)$ (polinomio de AR) y $\theta(z)$ (polinomio de MA) (No) deben de tener factores comunes.

- Si hay factores comunes se eliminan

2. Modelos dependientes del futuro

No nos interesa para nada un modelo AR cuyo X_t venga explicado por X_{t+1}, \dots, X_{t+h} . Entonces se introduce el concepto de causalidad:

- Un modelo ARMA es causal si puede escribirse como un proceso lineal de un solo lado:

$$X_t = \sum_{j=0}^{\infty} \psi_j \cdot W_{t-j}, \quad \psi_j = \text{coef. de representación.}$$

- Para garantizar causalidad, las raíces del polinomio $\phi(z)$ deben de estar fueras del círculo unitario del plano complejo ($|z| > 1$)

$\phi(z)$ en el AR es el operador de lags:

$$\phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p$$

Ejemplo AR(1):

$$X_t = \phi X_{t-1} + W_t$$

$$\phi(z) = 1 - \phi z \Rightarrow \phi(z) = 0 \Leftrightarrow z = 1/\phi$$

J. Si $|\phi| < 1 \Rightarrow |z| > 1 \Rightarrow$ Causalidad,

J. Si $|\phi| > 1 \Rightarrow |z| \leq 1 \Rightarrow$ No causalidad,

(*) Por qué?

Un modelo ARMA puede representarse como un proceso lineal infinito:

$$X_t = \sum_{j=0}^{\infty} \psi_j \cdot W_{t-j}, \text{ donde}$$

ψ_j viene determinado por: $\psi_j(z) = \frac{\theta(z)}{\phi(z)}$,

para que esta expresión sea válida, la suma infinita

$\sum_{j=0}^{\infty} |\psi_j|$ debe converger y esto solo ocurrirá

si $\phi(z)$ tiene todas sus raíces fuera del círculo unitario complejo ($|z| > 1$)

(*)₂ por qué?

Si escribimos $\phi(z) = 1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p$

- Cuando $|\phi| > 1$:

- Podemos poner $\frac{1}{\phi}$ como una serie de potencias convergente $\phi(z)$ en z , porque el denominador no tiene singularidades en el círculo unitario.
- Esto garantiza que los coef. ψ_j decrecen suficientemente rápido para que

$\sum_{j=0}^{\infty} |\psi_j| < \infty \Rightarrow$ la serie infinita que representa X_t converge.

3. Modelos no invertir

Un modelo MA podría tener múltiples representaciones equivalentes debido a la falta de restricciones en los parámetros. por eso introducimos el concepto de Invertibilidad:

- Un modelo ARMA es invertible si puede escribirse como un proceso AR infinito:

$$\Pi(B) X_t = \sum_{j=0}^{\infty} \pi_j \cdot X_{t-j} = W_t$$

• para garantizar invertibilidad, las raíces del polinomio $\theta(z)$ deben de estar fuera del círculo unitario del plano complejo

($|z| > 1$) (justificación análoga a condición 2)

Ejemplo de estas 3 condiciones:

- 1) Parameter Redundancy.
- 2) Causality.
- 3) Invertibility.

Consideremos:

$$X_t = \underbrace{0.4 \cdot X_{t-1} + 0.45 X_{t-2}}_{\text{(Recuerdos)}} + W_t + \underbrace{W_{t-1} + 0.25 W_{t-2}}_{\text{(análogos W_t)}}$$

En la forma de operadores:

$$(1 - 0.4B - 0.45B^2) X_t = (1 + B + 0.25B^2) W_t$$

$$\begin{aligned} &(\text{Recordos}) \quad X_{t-1} = BX_t \\ &X_{t-2} = B^2 X_t \quad (\text{análogos } W_t) \end{aligned}$$

Aparentemente parece un ARMA(2,2) pero veamos los polinomios asociados:

$$\begin{aligned} (1) \quad \phi(B) &= 1 - 0.4B - 0.45B^2 \quad (\text{AR}) \\ (2) \quad \theta(B) &= 1 + B + 0.25B^2 \quad (\text{MA}) \end{aligned} \quad] \Rightarrow$$

$$\Rightarrow \begin{cases} \bar{\phi}(z) = 1 - 0.4z - 0.45z^2 = (1 + 0.5z)(1 - 0.9z) \\ \bar{\theta}(z) = 1 + z + 0.25z^2 = (1 + 0.5z)^2 \end{cases}$$

Encontramos un factor común, podemos reducir el modelo:

$$\begin{aligned} \bar{\phi}(z) &= 1 - 0.9z \\ \bar{\theta}(z) &= 1 + 0.5z \end{aligned} \quad] \Rightarrow (1 - 0.9B) X_t = (1 + 0.5B) W_t \Leftrightarrow$$

$$\Leftrightarrow X_t = 0.9 X_{t-1} + 0.5 W_{t-1} + W_t$$

Entonces reducimos un ARMA(2,2) a un ARMA(1,1)

2. Causalidad

¿Es causal?

$$\bar{\phi}(z) = 1 - 0.9z \Rightarrow \text{la raíz cl } \phi = 0 \Rightarrow$$

$$\Rightarrow 1 - 0.9z = 0 \Rightarrow z = \frac{1}{0.9} \approx 1.11 > 1 \Rightarrow$$

Causalidad ✓

3. Invertibilidad

$$\bar{\theta}(z) = 1 + 0.5z \Rightarrow \theta = 0 \Rightarrow z = -\frac{1}{0.5} = -2 \Rightarrow$$

$$\Rightarrow |z| = 2 > 1 \Rightarrow \underline{\text{Invertibilidad}} \quad \checkmark$$

ACF y PACF

ACF

1. ACF de un proceso $MA(q)$

$MA(q)$ es de la forma:

$$X_t = \Theta(B) \cdot W_t = W_t + \theta_1 W_{t-1} + \theta_2 W_{t-2} + \dots + \theta_q W_{t-q}$$

dónde $\Theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$ es el operador polinómico de la media móvil.

• $E(X_t) = 0$ porque W_t es ruido blanco con media 0.

• La autocovarianza $\gamma(h)$ que es la covarianza entre X_t y X_{t+h} , es:

$$\gamma(h) = \text{Cov}(X_t, X_{t+h}) = \sigma_w^2 \sum_{j=0}^{q-h} \theta_j \cdot \theta_{j+h}, \quad 0 \leq h \leq q$$

esto básicamente significa que la covarianza se corta después de q lags.

* De ACF se obtiene dividiendo $\gamma(h)$ entre $\gamma(0)$:

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)} = \frac{\sum_{j=0}^{q-h} \theta_j \cdot \theta_{j+h}}{1 + \theta_1^2 + \dots + \theta_q^2}, \quad 1 \leq h \leq q \quad y$$

$$\rho(h) = 0.$$

Esto implica básicamente que $MA(q)$ tiene una ACF truncada más allá del lag q .

2. ACF de un ARMA(p, q)

ARMA(p, q):

$$\phi(B) \cdot X_t = \Theta(B) \cdot W_t$$

$$\gamma(h) = \sum_{j=1}^p \phi_j \cdot \gamma(h-j) + \sigma_w^2 \sum_{j=h}^q \theta_j \cdot \psi_{j-h}, \quad h > 0$$

Tras una serie de transformaciones, se obtiene una ecuación homogénea para hallar la ACF de un proceso ARMA, que es:

$$\gamma(h) - \phi_1 \cdot \gamma(h-1) - \dots - \phi_p \gamma(h-p) = 0, \quad h > \max(p, q+1)$$

y una ecuación no homogénea para los primeros h lags:

$$\gamma(h) - \sum_{j=1}^p \phi_j \cdot \gamma(h-j) = \sigma_w^2 \sum_{j=h}^q \theta_j \cdot \psi_{j-h}, \quad 0 \leq h \leq \max(p, q+1)$$

Se resuelve acabar y se llega a la ACF

$$\rho(h) = \gamma(h)/\gamma(0)$$

Comportamiento de la ACF en relación a los lags

- $h > q$ (en un proceso $MA(q)$), ACF es cero.

- $h > p$ (en un proceso $AR(p)$), ACF decays (extinguishes).

- ARMA(p, q)
 - ACF tiene un comportamiento combinado, con un corte después de q lags y decays lenta dependiendo de p .

PACF

= ARIMA model =

Def

El proceso X_t será un ARIMA (p, d, q) si:

$$\nabla^d X_t = (1 - B)^d X_t$$

es un ARMA (p, q) . En otras palabras, si se integral a corresponde con un ARMA (p, q) .

El modelo ARIMA (p, d, q) se expresa como:

$$\phi(B)(1 - B)^d X_t = \theta(B) \cdot w_t, \text{ donde:}$$

- $\phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$ captura la parte autogres.
- $\theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$ captura la media móvil.
- $(1 - B)^d$ aplica la diferenc. d veces para eliminar la tendencia o no estacionariedad.

Predicción con ARIMA

Es un poco más complejo debido a la no estacionariedad. La idea es trabajar con la serie diferenciada, donde $y_t = \Delta^d x_t$; predecir y_t usando los métodos de ARMA y luego integrar hacia atrás para obtener x_t .

Caso $d=1$:

por inducción

$$y_t = x_t - x_{t-1} \Rightarrow x_t = y_t + x_{t-1} \Rightarrow$$

$$\Rightarrow x_{t+u} = y_{t+u} + x_{t+u-1} \Rightarrow \boxed{x_{t+1} = y_{t+1} + x_t}$$

con la cond.
initial

Ejemplo simple: ARIMA $(1, 1, 0)$

$$\Delta x_t = \phi \cdot \Delta x_{t-1} + w_t \Rightarrow$$

$$\Rightarrow x_t = x_{t-1} + \phi(x_{t-1} - x_{t-2}) + w_t \quad /$$

= Construcción de un modelo ARIMA =

a) Inspección inicial de los datos.

1) Graficar la serie temporal (identificar patrones, anomalías, tendencias...)

2) Transformaciones

2.1) Si la varianza no es cte., se puede aplicar una transformación Box-Cox para estabilizarla.

b) Identificación preliminar de p, d, q

1)

1.1) Inspeccionar el gráfico original

1.2) Si hay tendencia constante, diferenciar 1 vez.

1.3) Si aún persiste la tendencia, diferenciar otra vez.

1.4) Ojo, sobre diferenciar puede introducir dependencias artificiales

2) Usos de la ACF

• Si la serie no es estacionaria, la ACF decays lentamente a medida que h aumenta.

• Una lentitud en el decaimiento de ACF indica que se necesita diferenciar.

c) Selección de p y q

1. Trabajar con la serie diferenciada ($\Delta^d X_t$)

• Una vez elegido d, analizar ACF y PACF de la serie estacionaria resultante.

2. Guía para identificar p y q

• $p=0, q>0 \Rightarrow \begin{cases} \cdot \text{ACF corta lag } q \\ \cdot \text{PACF decays lentamente} \end{cases}$

• $q=0, p>0 \Rightarrow \begin{cases} \cdot \text{ACF decays lentamente} \\ \cdot \text{PACF corta en lag } p. \end{cases}$

• $q>0, p>0 \Rightarrow \begin{cases} \cdot \text{ACF decays lentamente} \\ \cdot \text{PACF decays lentamente} \end{cases}$

= Grupo AIMA: Análisis datos GNP =

Son datos de la evolución del producto nacional bruto de EEUU.

- * El gráfico inicial muestra una clara tendencia (no estacionariedad) por lo que hay que diferenciar.
- * La primera diferencia elimina la tendencia lineal, sin embargo, la varianza sigue siendo mayor en el 2º tramo del periodo.
- * Aplicamos transformación logarítmica para aneglar eso ($y_t = \nabla \log(y_0)$) y llegamos a un proceso más estable que parece cumplir con los C.N para seguir.

* Analizamos ACF y PACF

ACF: Corta en el lag 2 \Rightarrow MA(2)

PACF: Corta en el lag 1 \Rightarrow AR(1)

Entonces consideramos dos modelos preliminares para $\nabla \log(GNP)$:

1. MA(2)

2. AR(1)

1. MA(2)

de ecuación ajustada es:

$$y_t = 0'008 + 0'303 w_{t-1} + 0'204 w_{t-2} + w_t$$

(A la cual se llegó mediante métodos numéricos como Newton-Raphson)

da cte. 0'008 indica un crecimiento medio del 0'8% trimestral.

2. AR(1)

$$y_t = 0'008 (1 - 0'347) + 0'347 y_{t-1} + w_t$$

Ambos modelos presentan parámetros estadíst. significativos.

= Seasonal ARMA model =

Los SARMA son extensiones de los modelos ARMA estacionar para hallar patrones estacionales en los datos.

- * Son útiles cuando las dependencias en una serie temporal no solo ocurren en los lags inmediatos ($t-1, t-2, \dots$) sino que también ocurren en lags que coinciden con períodos estacionales ($t-5, t-25, \dots$)

- Estructura de un ARMA($p, Q)_S$

$$\Phi_p(B^S)X_t = \Theta_Q(B^S)W_t, \text{ donde}$$

$\Phi_p \equiv$ Operador autoregresivo estacional de orden P y periodo S .

$\Theta_Q \equiv$ Operador móvil estacional de orden Q y periodo S .

* $\Phi_p(B^S)$

Captura la influencia de valores pasados en lags estacionales ($t-5, t-25, \dots$)

$$\Phi_p(B^S) = 1 - \phi_1 B^S - \phi_2 B^{2S} - \dots - \phi_p B^{PS}$$

Por ejemplo, si $P=2$ y el periodo es anual ($S=12$):

$$\Phi_2(B^{12}) = 1 - \phi_1 B^{12} - \phi_2 B^{24}$$

• ϕ_1 representa la influencia del valor de la serie hace 12 periodos y ϕ_2 hace 24 periodos.

* $\Theta_Q(B^S)$

Captura la influencia de errores pasados en lags estacionales ($t-5, t-25, \dots$)

$$\Theta_Q(B^S) = 1 + \theta_1 B^S + \theta_2 B^{2S} + \dots + \theta_Q B^{QS}$$

Propiedades de un modelo estacional

- 1) Causalidad: Las raíces de $\Phi_p(z^S)$ deben de estar fuera del círculo unitario.
- 2) Invertibilidad: Las raíces de $\Theta_Q(z^S)$ deben de estar fuera del círculo unitario.

Ejemplo ARMA(1,1)₁₂

Hipótesis una serie mensual con un componente anual ($S=12$). Un modelo ARMA(1,1)₁₂ sería:

$$(1 - \phi_1 B^{12})X_t = (1 + \theta_1 B^{12})W_t$$

Si $\phi_1 = 0.8$ y $\theta_1 = 0.4$, el modelo sería:

$$[X_t = 0.8 X_{t-12} + W_t + 0.4 \cdot W_{t-12}]$$

- El valor actual de X_t depende en un 80% del valor de hace 12 meses
- También depende en un 40% del error pasado W_{t-12}

= Sección ARIMA model =

Son extensiones de los modelos ARIMA para series temporales que presentan estacionalidad.

OJO: No confundir estacionalidad con estacionariedad.

DIF

El modelo SARIMA se denota como:

$$ARIMA(p,d,q) \times (P,D,Q)_S$$

Ejemplo

Analizaremos un modelo ARIMA $(0,1,1) \times (0,1,1)_12$

1. Parte no estacional

- $p=0$: No hay térm. autoreg. no estacionales.
- $d=1$: Diferenciación para eliminar tendencia.
- $q=1$: Término promedio móvil no estacional

2. Parte estacional

- $P=0$: No hay términos autoreg. estacionales
- $D=1$: Diferenciación estacional con $s=12$ para eliminar estacionalidad anual
- $Q=1$: Términ. promedio móvil estacional.

El modelo resulta:

$$(1 - B^{12}) (1 - B) X_t = (1 + \theta B^{12}) (1 + \theta B) W_t \Leftrightarrow$$

$$\Leftrightarrow X_t = X_{t-1} + X_{t-12} + W_t + \theta W_{t-1} + \theta W_{t-12} + \theta \theta W_{t-13}$$

Lo cual muestra que los valores actuales X_t de la serie dependen de:

- Su valor inmediatamente anterior X_{t-1}
- Su valor 12 meses antes X_{t-12}
- Combinaciones lineales de los residuos pasados (W_t, W_{t-1}, \dots)

Análisis de datos

- Se grafican los datos y se ve una muy clara tendencia no estacionaria creciente y estacionalidad anual.

1. Primera diferencia

→ Para eliminar la tendencia se deriva una vez.

$$\nabla X_t = X_t - X_{t-1}$$

→ Al graficar el ACF se observan picos en los lags estacionales ($12, 24, 36, \dots$), lo que indica persistente estacionalidad.

2. Diferencia estacional

$$\nabla_{12} \nabla X_t = (1 - B^{12}) (1 - B) X_t$$

Se aplica para eliminar las influencias estacionales de una serie temporal.

* ¿Qué ocurre con la ACF y PACF tras esta diferenciación?

• ACF

Se observa un pico significativo en el lag 12 (lo cual significa que la correlación más fuerte en la serie ocurre tras 12 períodos).

Tras este pico, el ACF muestra decadimiento a medida que aumentan los lags (lo cual significa que la serie ya ha sido suficientemente estabilizada por la diferencia estacional).

• PACF

La PACF por su parte se atenúa en los lags estacionales.

Selección del modelo

1. ACF. El hecho de que ACF se atenúa en el lag 12, indica que el modelo debe de tener un componente estacional que capture esas fluctuaciones.
2. PACF. La atenuación en los lags estacionales indica que se debe de considerar una componente de media móvil estacional (SMA).

• ACF. El hecho de que ACF se atenúa en el lag 12, indica que el modelo debe de tener un componente estacional que capture esas fluctuaciones.

• PACF. La atenuación en los lags estacionales indica que se debe de considerar una componente de media móvil estacional (SMA).

• ACF. El hecho de que ACF se atenúa en el lag 12, indica que el modelo debe de tener un componente estacional que capture esas fluctuaciones.

• PACF. La atenuación en los lags estacionales indica que se debe de considerar una componente de media móvil estacional (SMA).

• ACF. El hecho de que ACF se atenúa en el lag 12, indica que el modelo debe de tener un componente estacional que capture esas fluctuaciones.

• PACF. La atenuación en los lags estacionales indica que se debe de considerar una componente de media móvil estacional (SMA).

• ACF. El hecho de que ACF se atenúa en el lag 12, indica que el modelo debe de tener un componente estacional que capture esas fluctuaciones.

• PACF. La atenuación en los lags estacionales indica que se debe de considerar una componente de media móvil estacional (SMA).

• ACF. El hecho de que ACF se atenúa en el lag 12, indica que el modelo debe de tener un componente estacional que capture esas fluctuaciones.

• PACF. La atenuación en los lags estacionales indica que se debe de considerar una componente de media móvil estacional (SMA).

• ACF. El hecho de que ACF se atenúa en el lag 12, indica que el modelo debe de tener un componente estacional que capture esas fluctuaciones.

• PACF. La atenuación en los lags estacionales indica que se debe de considerar una componente de media móvil estacional (SMA).

• ACF. El hecho de que ACF se atenúa en el lag 12, indica que el modelo debe de tener un componente estacional que capture esas fluctuaciones.

• PACF. La atenuación en los lags estacionales indica que se debe de considerar una componente de media móvil estacional (SMA).

• ACF. El hecho de que ACF se atenúa en el lag 12, indica que el modelo debe de tener un componente estacional que capture esas fluctuaciones.

• PACF. La atenuación en los lags estacionales indica que se debe de considerar una componente de media móvil estacional (SMA).

ACF y PACF en modelos mixtos

Modelo	ACF	PACF
/ / / / /	/ / / / /	/ / / / /
AR(p)	Decae lentamente	Corte en el lag p
MA(q)	Corte en el lag q	Decae lentamente
SAR(P)	Decae lentamente en los estacionales (S, 2S...)	Corte después del lag PS
SMA(Q)	Corte en el lag QS	Decae lentamente a los estacionales
ARIMA(p,q)	Cae lentamente	Decae lentamente
SARIMA(p,q)	Decae lentamente en los estacionales	Decae lentamente en los estacionales

$$[\text{SARIMA}(p, d, q) \times (P, D, Q)_S]$$